Pycon 2021

MLflow를 이용한 머신러닝 실험부터 배포까지

sean.park@mathpresso.com

박선준 (Sean)

QANDA, Everyone's Personal Tutor.

MATHPRESSO

Image Search "Strong Entry Point"

- 풀이검색
- 수식 계산기
- 1:1 Q&A

Study Tools "Higher Engagement"

- 개념 검색
- 계산기
- 사전
- 스터디 그룹

Personalized Content "Effective Learning"

- 동영상 강의
- 문제집
- 라이브 강의

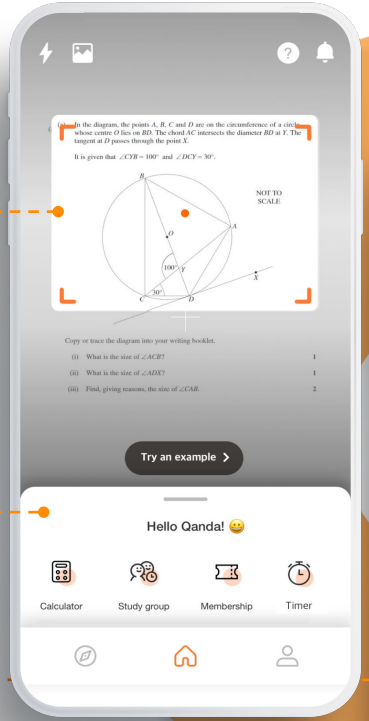

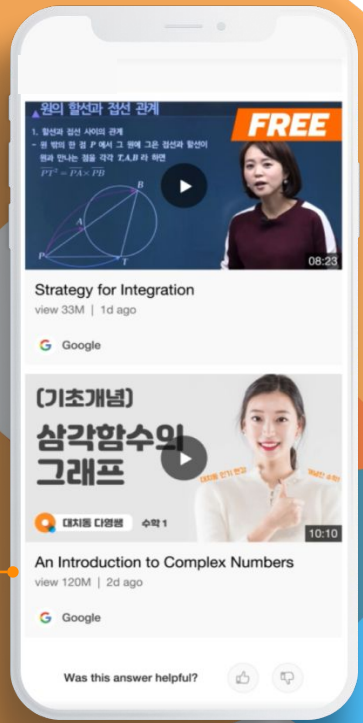

누적 앱 다운로드	월간 활성 사용자 (MAU)	일 평균 질문수	초당 업로드수	누적 문제해결수
36M	**9.8M**	**6.4M**	**74**	**2.5BN**

교육차트 1위
20개국

누적 투자액
$105M+

지원언어
7 KR,JP,VN,ID,TH,EN,ES

Source: Based on Firebase SDK, Aug 2021.

Agenda.

1. 머신러닝 실험부터 배포까지

1.1 머신러닝 프로젝트의 어려움

1.2 MLflow Tracking

1.3 MLflow Model

1.4 Serving with MLflow

1.5 회사의 활용 사례 소개

2. MLflow 을 이용한 실습

2.1 tracking server 를 설정하고 S3 와 연동하기

2.2 MLflow 에 모델 기록하기

2.3 mlflow에 기록된 모델을 Docker Image 화 하고, 실행시켜보기

1.1 머신러닝 프로젝트의 어려움

각 실험을 체계적으로 파악하고 관리하기가 어렵습니다.

- 어떤 데이터를 이용해서 학습을 진행했었지 ?
- 이 모델에서 사용된 Feature 는 어떤 것이었지 ?
- 어떤 Parameter 를 이용해서 학습을 진행했었지 ?
- 실험 결과가 어디에 저장되어 있지 ?
- 학습된 모델의 버전은 어떻게 관리하지 ?
- 학습에 사용된 코드는 어떤 버전이지 ?

모델을 배포하는 것에 난이도가 있습니다.

- 사용하는 프레임워크가 연구자마다 상이한데, 배포는 어떤 방식으로 진행하지?
- 배포된 모델의 버전관리는 어떻게하지?

1.2 MLflow Tracking

1. **Tracking** - 실험에서 사용된 코드, parameter, metric 등 실험에서 생산되는 모든 결과를 기록하고 조회할 수 있습니다. Python, REST, R, JAVA APIs 를 제공합니다.
2. **Project** - 어떤 플랫폼에서도 실험을 재현 가능하도록 패키징하는 방법을 제공합니다.
3. **Models** - 머신러닝 모델을 패키징하고, 서빙할 수 있는 표준화된 방법을 제안합니다.

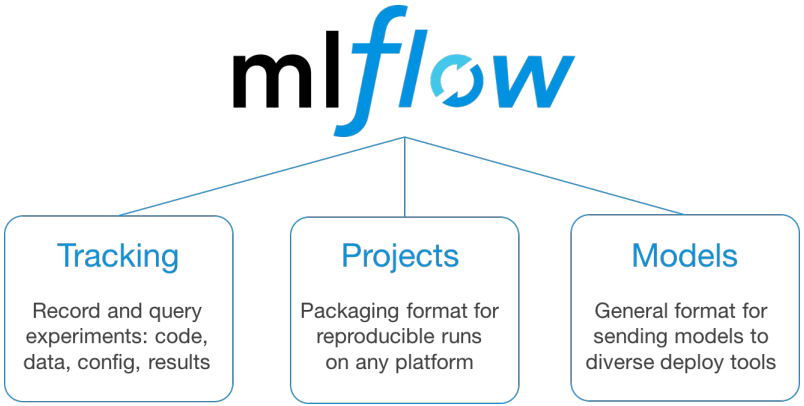

1.2 MLflow Tracking

Parameters : key-value inputs to your code

Metrics : numeric values that can update over time

Artifacts : files, including data and models

Tags and Notes : any additional information

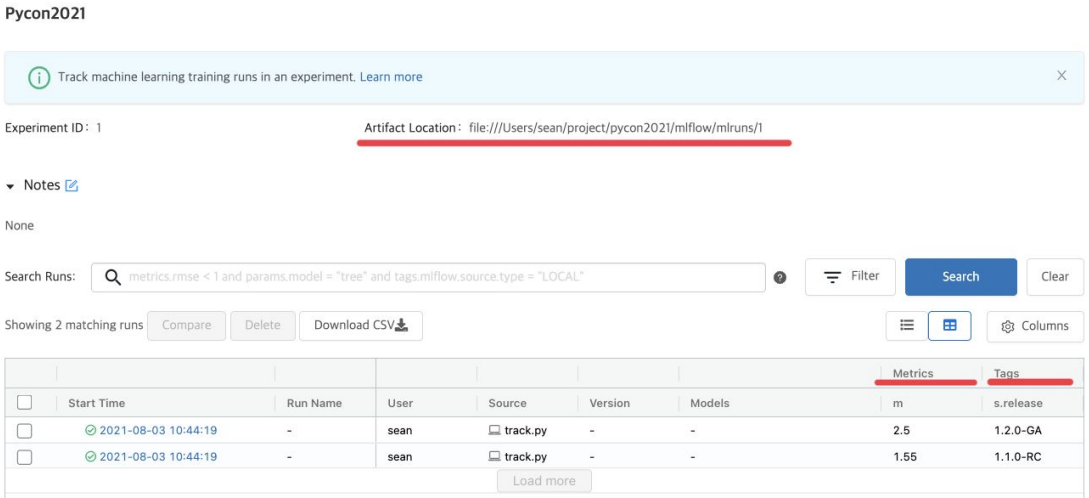

MATHPRESSO

1.2 MLflow Tracking

```python
import mlflow


if __name__ == "__main__":

    mlflow.set_tracking_uri("http://localhost:5000")

    # Create an experiment and log two runs under it
    experiment_id = mlflow.create_experiment("Pycon2021")

    with mlflow.start_run(experiment_id=experiment_id):
        mlflow.log_metric("m", 1.55)
        mlflow.set_tag("s.release", "1.1.0-RC")

    with mlflow.start_run(experiment_id=experiment_id):
        mlflow.log_metric("m", 2.50)
        mlflow.set_tag("s.release", "1.2.0-GA")

    # Search all runs in experiment_id
    df = mlflow.search_runs([experiment_id], order_by=["metrics.m
    print(df[["metrics.m", "tags.s.release", "run_id"]])
    print("--")

    # Search the experiment_id using a filter_string with tag
    # that has a case insensitive pattern
    filter_string = "tags.s.release ILIKE '%rc%'"
    df = mlflow.search_runs([experiment_id], filter_string=filter
    print(df[["metrics.m", "tags.s.release", "run_id"]])
```

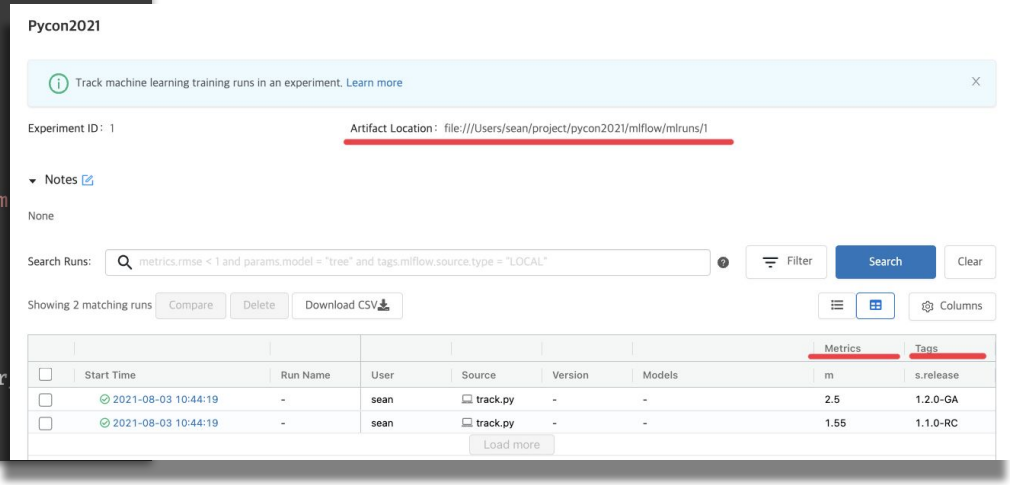

1.2 MLflow Tracking

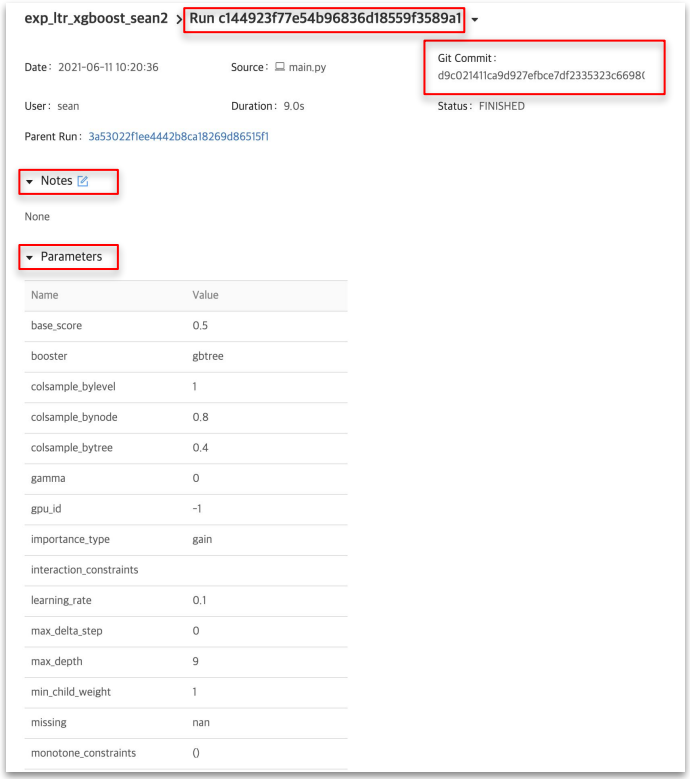

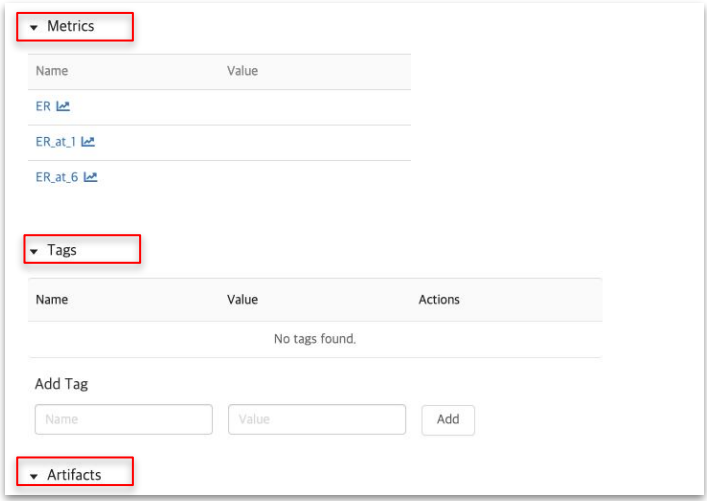

1.2 MLflow Tracking - Metric

- Accuray / Loss 등 임의의 Metric 을 실험 마다 기록해 둘 수 있다.
- 이는 진행된 **실험 간 비교를 할 때 유용**하게 사용할 수 있다.

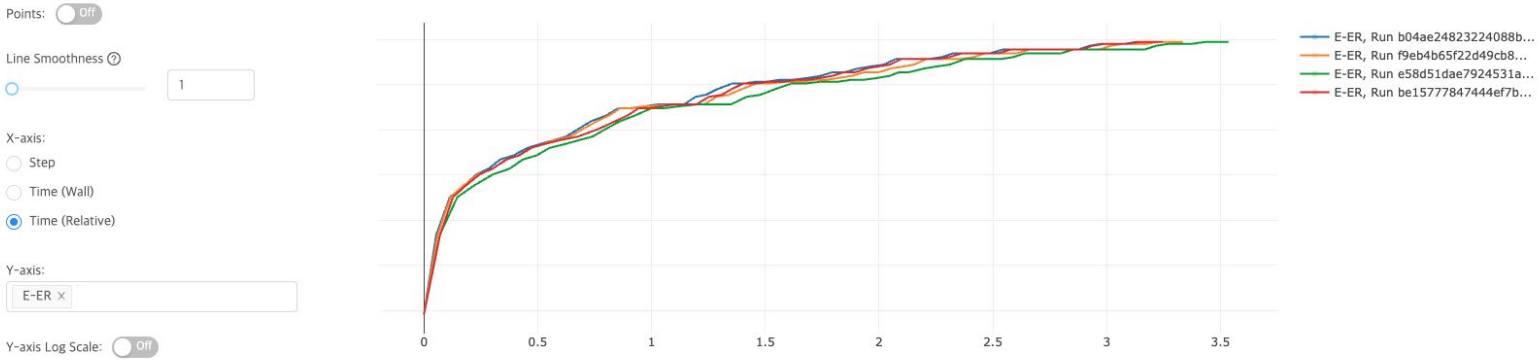

1.2 MLflow Tracking - Tags

- 각 실험에 임의의 Tag 를 달아 둘 수 있다.

- Search Runs 기능을 통하여 tag 를 이용하여 **실험에 필터를 걸어서** 원하는 실험을 찾아볼 수 있다.

- 완료된 실험들의 결과를 **해석할 때 유용**하게 사용할 수 있다.

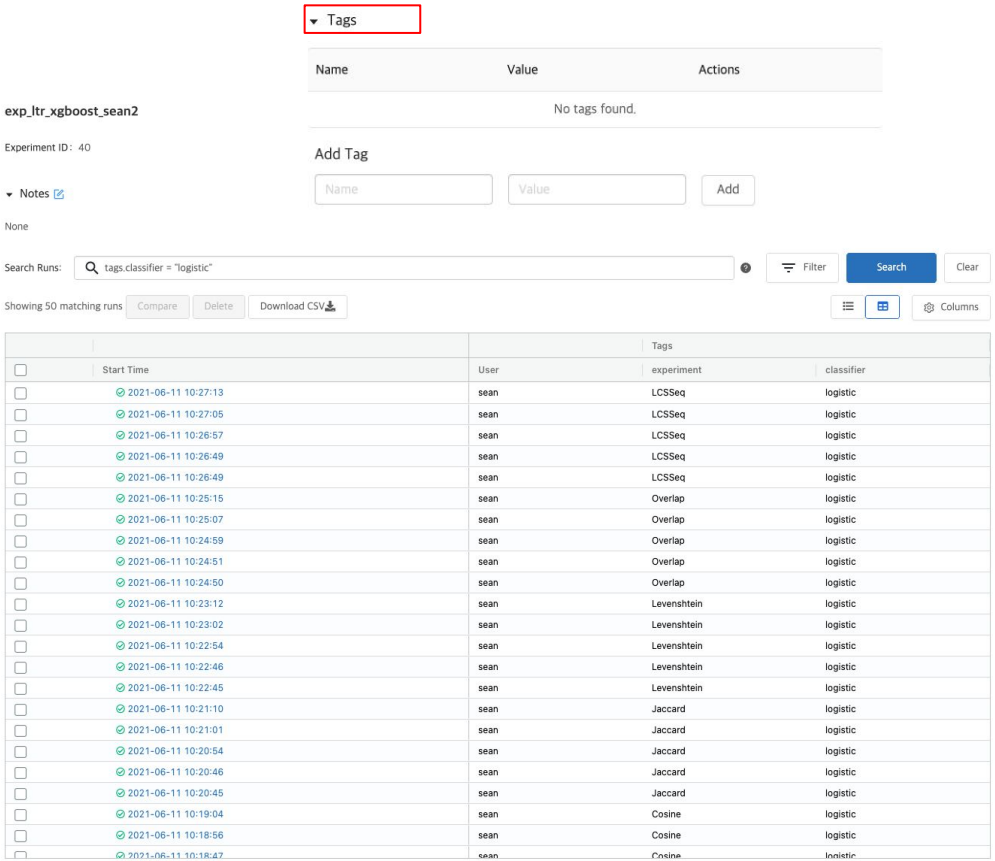

1.2 MLflow Tracking - Metric & Parameter

- Tag 를 통하여 실험을 필터링하여, **Parameter 와 Metric 의 상관관계를 분석할 수 있다.**

- 왼쪽 예시는 Accuracy 와 xgboost 의 parameter 인 colsample_bytree 간의 상관관계를 보여준다.

- colsample_by_tree가 낮을 수록 더 높은 정확도를 보임을 확인할 수 있다.

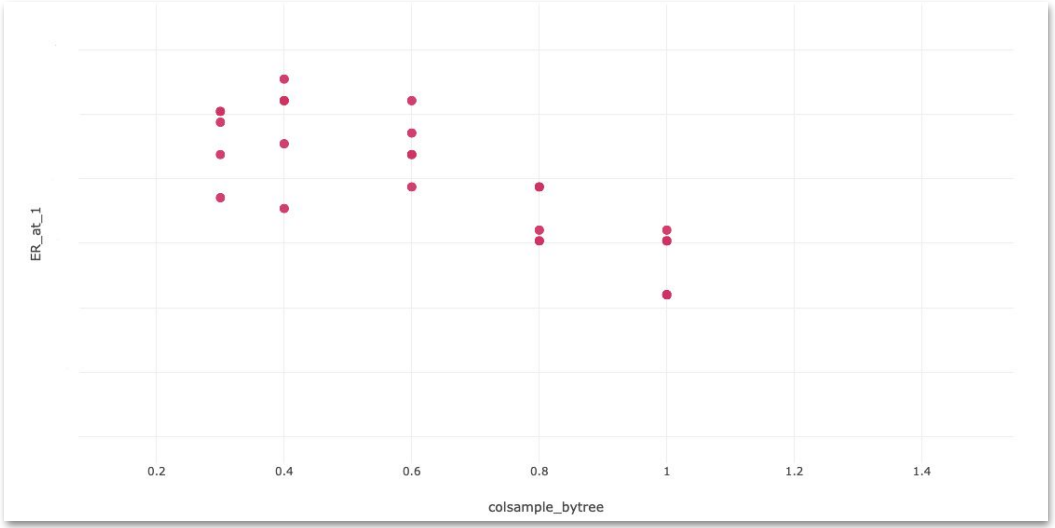

1.2 MLflow Tracking - Artifacts

- 실험에 사용된 **<u>임의의 파일을 업로드</u>**하여 관리할 수 있다.

- 아래 예시는 xgboost 의 Feature importance 를 matplotlib을 통하여 시각화한 자료

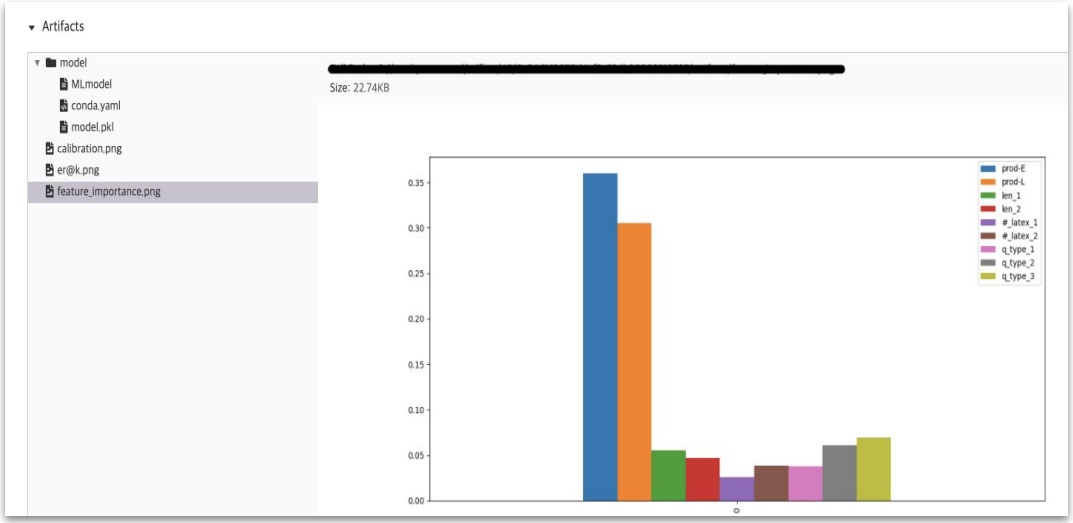

1.3 MLflow Models

```python
import numpy as np
from sklearn.linear_model import LogisticRegression

import mlflow
import mlflow.sklearn

if __name__ == "__main__":

    X = np.array([-2, -1, 0, 1, 2, 1]).reshape(-1, 1)
    y = np.array([0, 0, 1, 1, 1, 0])
    lr = LogisticRegression()
    lr.fit(X, y)

    experiment = mlflow.get_experiment_by_name("Pycon2021")
    with mlflow.start_run(experiment_id=experiment.experiment_id):
        score = lr.score(X, y)
        print("Score: %s" % score)
        mlflow.log_metric("score", score)
        mlflow.sklearn.log_model(lr, "model")
        print("Model saved in run %s" % mlflow.active_run().info.run_uuid)
```

MATHPRESSO

1.3 MLflow Models

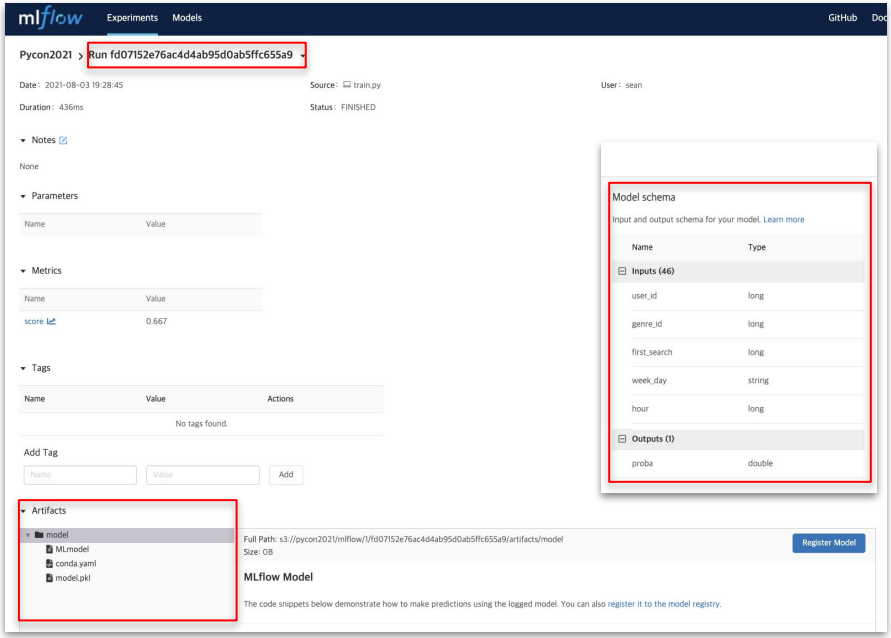

1.1 머신러닝 프로젝트의 어려움

각 실험을 체계적으로 파악하고 관리하기가 어렵습니다.

- 어떤 데이터를 이용해서 학습을 진행했었지 ? **- mlflow artifact / ETL script with git**
- 이 모델에서 사용된 Feature 는 어떤 것이었지 ? **- mlflow logging**
- 어떤 Parameter 를 이용해서 학습을 진행했었지 ? **- mlflow logging**
- 실험 결과가 어디에 저장되어 있지 ? **- mlflow (tracking server / s3)**
- 학습된 모델의 버전은 어떻게 관리하지 ? **- mlflow model run id**
- 학습에 사용된 코드는 어떤 버전이지 ? **- mlflow with git**

모델을 배포하는 것에 난이도가 있습니다.

- 사용하는 프레임워크가 연구자마다 상이한데, 배포는 어떤 방식으로 진행하지?
- 배포된 모델의 버전관리는 어떻게하지?

1.3 MLflow Models - Flavor

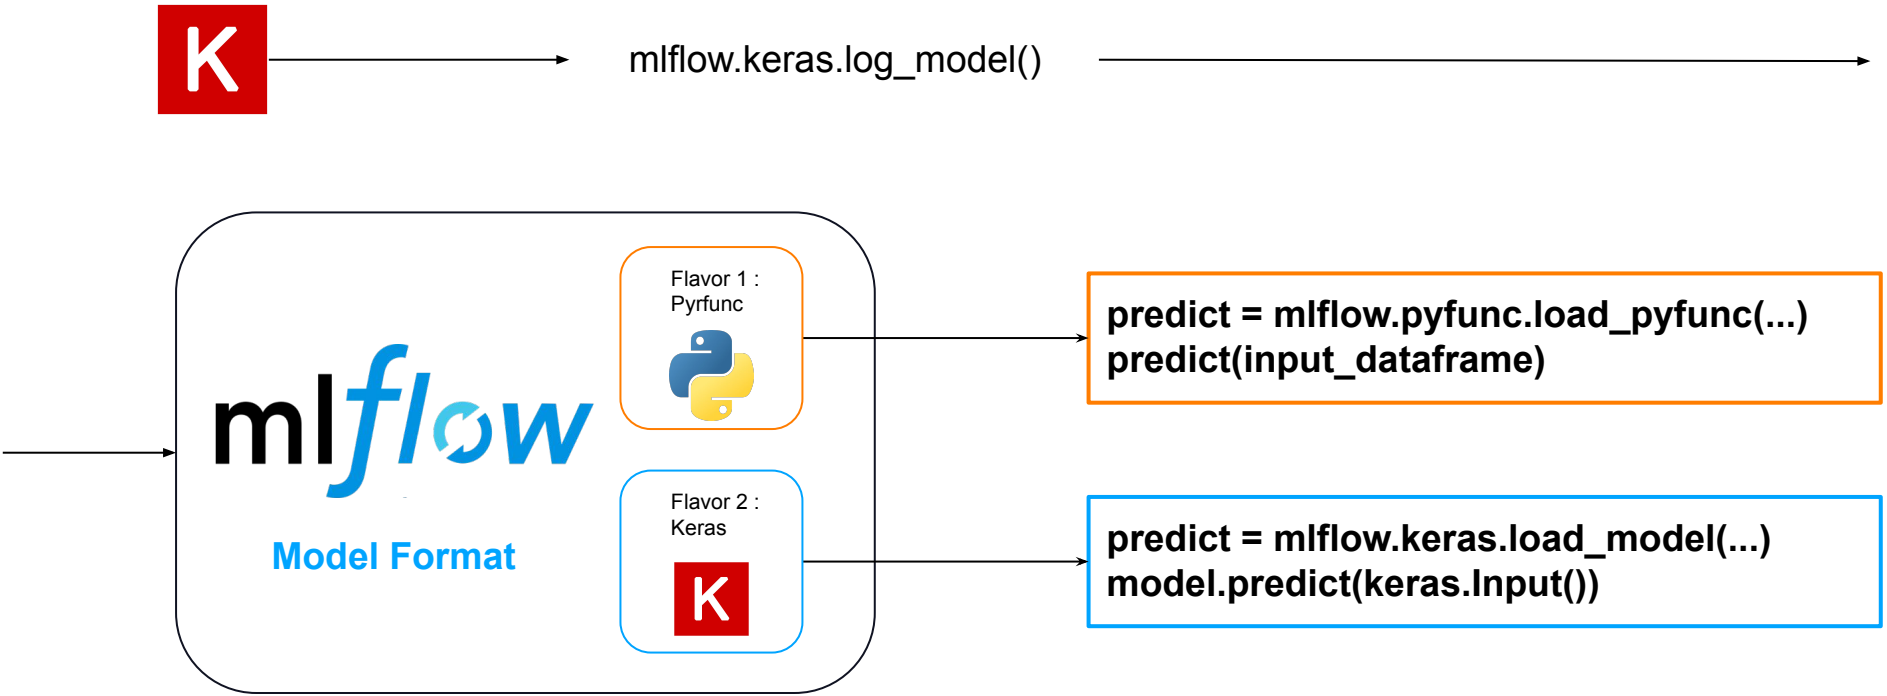

Source: https://www.youtube.com/watch?v=859OxXrt_TI&t=1806s

1.3 MLflow Models - Flavor

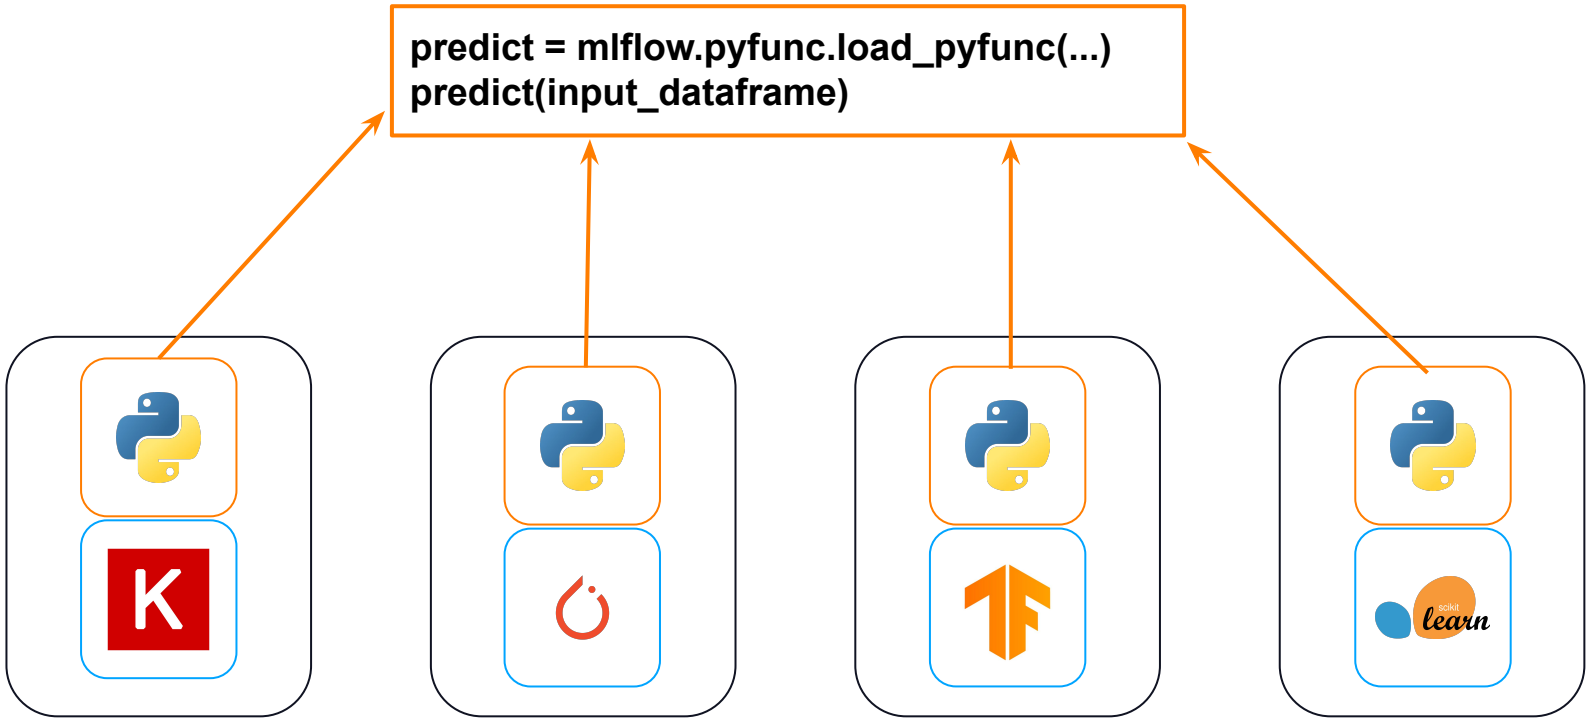

Source: https://www.youtube.com/watch?v=859OxXrt_TI&t=1806s

1.3 MLflow Models

Model schema

Input and output schema for your model. Learn more

Name	Type
Inputs (36)	
user_id	long
genre_id	long
first_search	long
week_day	string
hour	long
Outputs (1)	
proba	double

Make Predictions

Predict on a Spark DataFrame:

```
import mlflow
logged_model = 's3://mathpresso-rnd/[redacted]'

# Load model as a Spark UDF.
loaded_model = mlflow.pyfunc.spark_udf(logged_model)

# Predict on a Spark DataFrame.
df.withColumn(loaded_model, 'my_predictions')
```

Predict on a Pandas DataFrame:

```
import mlflow
logged_model = 's3://mathpresso-rnd/[redacted]'

# Load model as a PyFuncModel.
loaded_model = mlflow.pyfunc.load_model(logged_model)

# Predict on a Pandas DataFrame.
import pandas as pd
loaded_model.predict(pd.DataFrame(data))
```

1.4 Serving with MLflow

- mlflow models 는 실험적 기능으로 build-docker 기능을 제공합니다.
- build-docker 명령어는 Flask 기반의 웹 서버를 이미지화합니다.
- /ping 과 /invocations 두 종류의 endpoint를 제공하며 /invocations 을 통하여 mlflow에 저장된 모델의 추론 결과를 반환받을 수 있습니다.

```
def init(model: PyFuncModel):

    """
    Initialize the server. Loads pyfunc model from the path.
    """
    app = flask.Flask(__name__)
    input_schema = model.metadata.get_input_schema()

    @app.route("/ping", methods=["GET"])
    def ping():  # pylint: disable=unused-variable
        """
        Determine if the container is working and healthy.
        We declare it healthy if we can load the model successfully.
        """
        health = model is not None
        status = 200 if health else 404
        return flask.Response(response="\n", status=status, mimetype="application/json")

    @app.route("/invocations", methods=["POST"])
    @catch_mlflow_exception
    def transformation():  # pylint: disable=unused-variable
        """
        Do an inference on a single batch of data. In this sample server,
        we take data as CSV or json, convert it to a Pandas DataFrame or Numpy,
        generate predictions and convert them back to json.
        """
```

1.4 Serving with MLflow

- Flask Application 은 gunicorn 과 nginx 를 앞단에 감싸줌으로써 효과적으로 cpu 사용합니다.

- 즉, build-docker 명령어는 Flask + gunicorn + nginx 기반의 웹 서버를 이미지화하며, 추가적인 gunicorn 설정을 넣어 줄 수 있습니다.

```
def _serve_pyfunc(model):
    conf = model.flavors[pyfunc.FLAVOR_NAME]
    bash_cmds = []
    if pyfunc.ENV in conf:
        if not os.environ.get(DISABLE_ENV_CREATION) == "true":
            _install_pyfunc_deps(MODEL_PATH, install_mlflow=True)
        bash_cmds += ["source /miniconda/bin/activate custom_env"]
    nginx_conf = resource_filename(mlflow.models.__name__, "container/scoring_server/nginx.conf")

    # option to disable manually nginx. The default behavior is to enable nginx.
    start_nginx = False if os.getenv(DISABLE_NGINX, "false").lower() == "true" else True
    nginx = Popen(["nginx", "-c", nginx_conf]) if start_nginx else None

    # link the log streams to stdout/err so they will be logged to the container logs.
    # Default behavior is to do the redirection unless explicitly specified by environment variable.

    if start_nginx:
        check_call(["ln", "-sf", "/dev/stdout", "/var/log/nginx/access.log"])
        check_call(["ln", "-sf", "/dev/stderr", "/var/log/nginx/error.log"])

    cpu_count = multiprocessing.cpu_count()
    os.system("pip -V")
    os.system("python -V")
    os.system('python -c"from mlflow.version import VERSION as V; print(V)"')
    cmd = (
        "gunicorn -w {cpu_count} ".format(cpu_count=cpu_count)
        + "${GUNICORN_CMD_ARGS} mlflow.models.container.scoring_server.wsgi:app"
    )
    bash_cmds.append(cmd)
    gunicorn = Popen(["/bin/bash", "-c", " && ".join(bash_cmds)])

    procs = [p for p in [nginx, gunicorn] if p]

    signal.signal(signal.SIGTERM, lambda a, b: _sigterm_handler(pids=[p.pid for p in procs]))
    # If either subprocess exits, so do we.
    awaited_pids = _await_subprocess_exit_any(procs=procs)
    _sigterm_handler(awaited_pids)
```

1.4 회사에서 활용 사례 소개

- 많은 ML 엔지니어의 백그라운드가 SW에 있지 않기 때문에, 앞선 Iteration에 있어 병목이 발생합니다.

- ML 엔지니어의 가장 큰 병목인 배포 과정을 MLflow를 통하여 자동화하여 배포의 난이도를 낮춰 ML 프로덕트 개발 속도를 증진시키고자 하는 목적이 있었습니다.

- MLflow 에서 제공하는 Model Packaging 기능을 활용하여 배포의 난이도를 낮추고자 함.

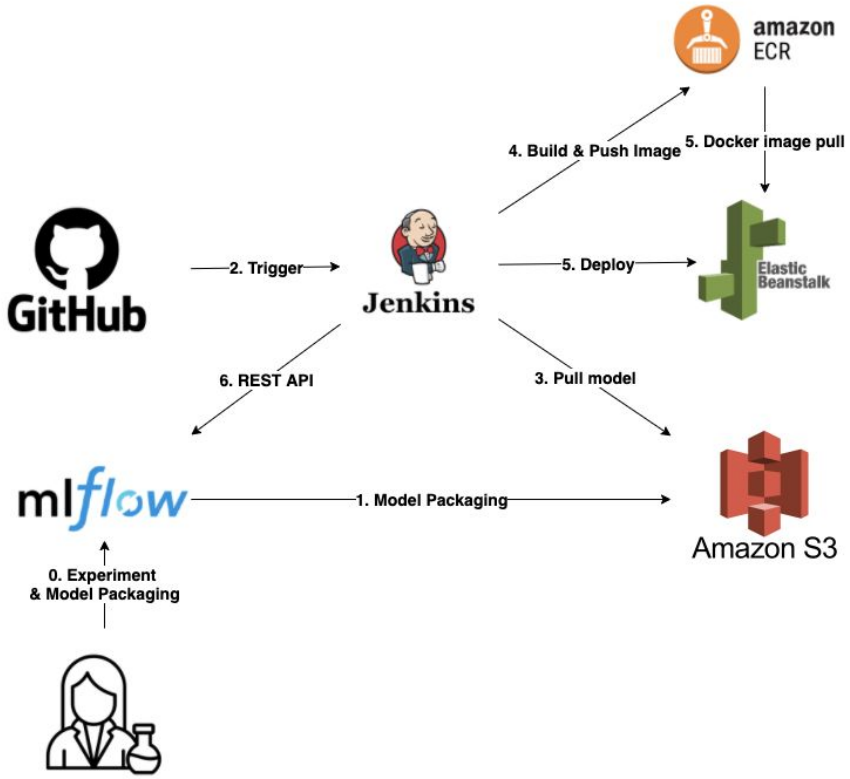

1.4 회사에서 활용 사례 소개 - 실험 및 모델 패키징

[redacted] / ai-team-notebook Private

Code | Issues | Pull requests | Actions | Projects | Wiki | Security | Insights | Settings

master | 3 branches | 14 tags | Go to file | Add file | Code

[redacted] Add GraphValidator ipynb — f3934b4 5 hours ago — 174 commits

analysis	Add GraphValidator ipynb	5 hours ago
data	Merge branch 'master' of github.com:mathpresso/ai-team-notebook	2 months ago
external-request/sean	Add community feed related materials	4 months ago
nlp	Merge pull request #18 from mathpresso/sean/search-ltr-wo-lm	13 days ago
ocr	Add ocr directory and move projects	4 months ago
recommend	add test_local.py	2 months ago
video-solution	Add sq_postprocess.py for uq clustering.	3 months ago
.gitignore	Add gitignore MacOS cache files	10 months ago
Dockerfile	update deploy scripts	4 months ago
Dockerrun.aws.json	update deploy scripts	4 months ago
Jenkinsfile	Add mlflow log deploy history to Jenkinsfile	4 months ago
README.md	Update project structure to Readme.md	4 months ago
build-docker.sh	update help	5 months ago
download_artifacts.sh	Update jenkinsfile 1	4 months ago
gunicorn_conf.py	update deploy scripts	4 months ago

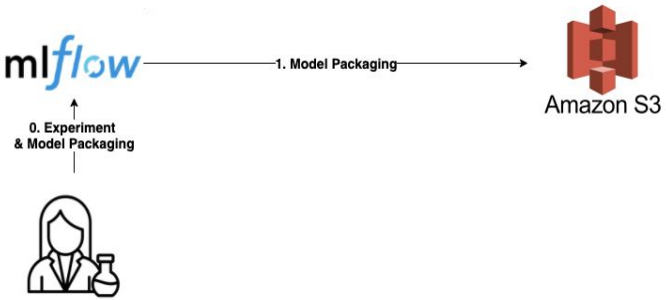

1.4 회사에서 활용 사례 소개 - Jenkins

- {datetime}@{**run_id**}@{project_path}@{eb_app}/{eb_env}
- github 에 Tag 를 달면 Tag의 내용을 기반하여 배포가 수행된다.

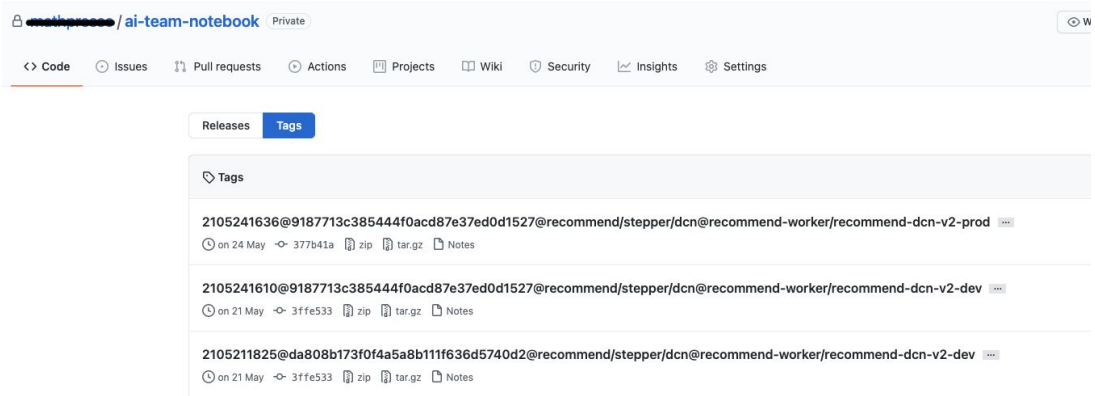

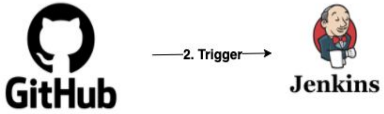

1.4 회사에서 활용 사례 소개 - ElasticBeanstalk

- 로드 밸런싱, Auto Scaling부터 시작하여 애플리케이션 상태 모니터링에 이르기까지 배포를 자동으로 처리합니다.
- ElasticBeanstalk → k8s

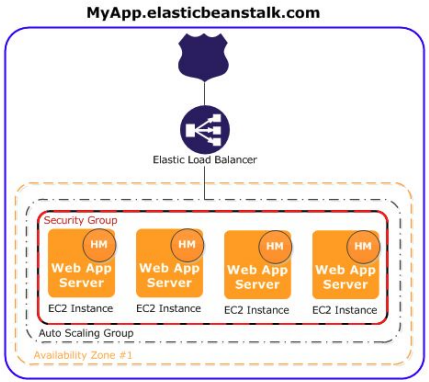

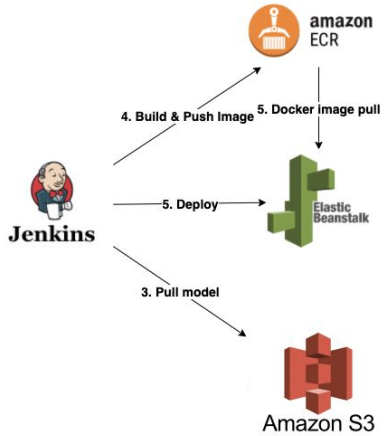

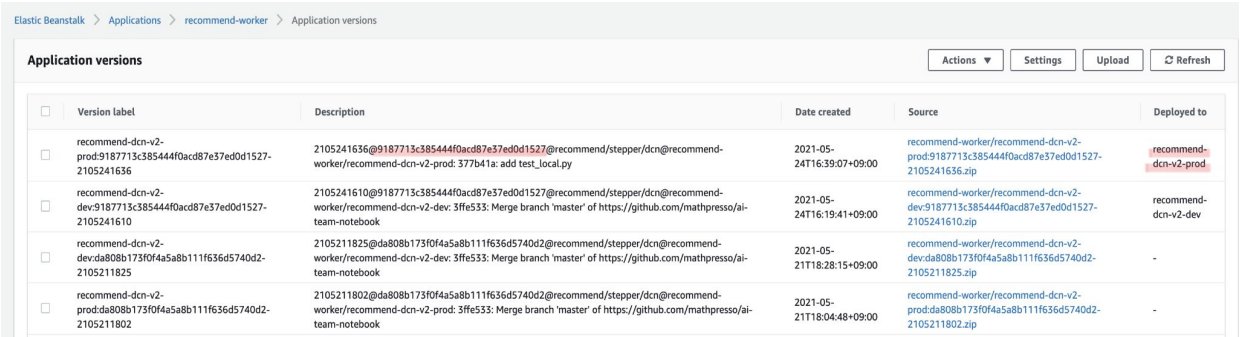

1.4 회사에서 활용 사례 소개 - Model Registry

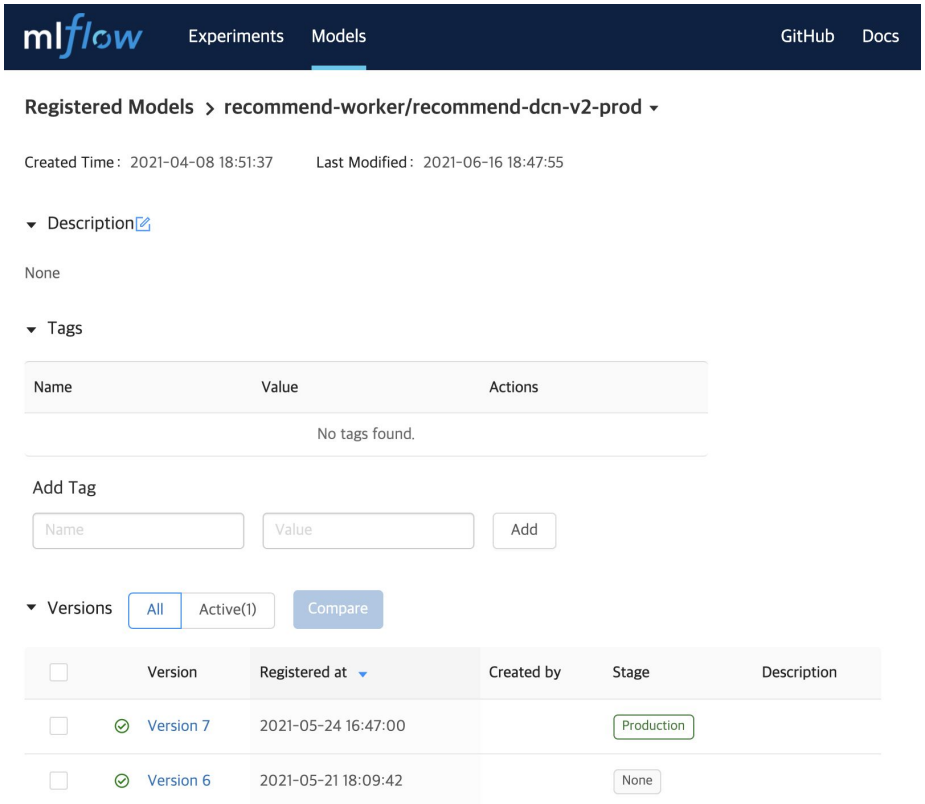

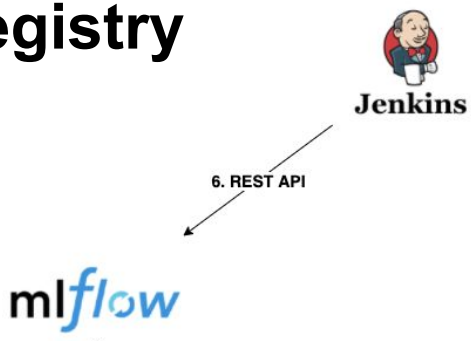

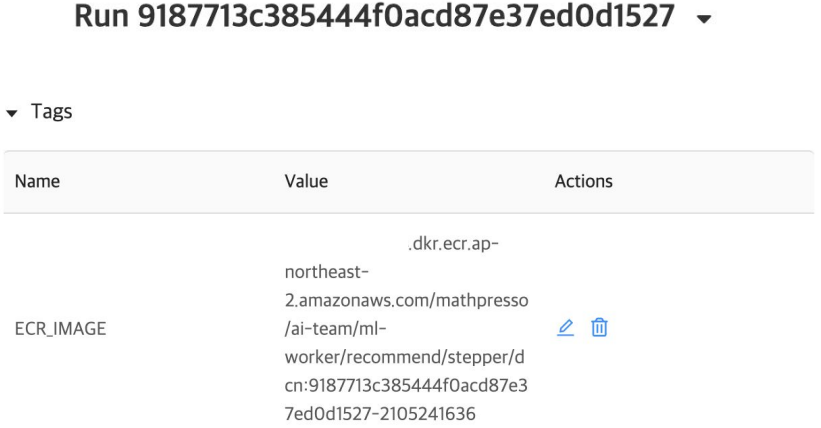

1.1 머신러닝 프로젝트의 어려움

각 실험을 체계적으로 파악하고 관리하기가 어렵습니다.

- 어떤 데이터를 이용해서 학습을 진행했었지 ? **- mlflow artifact / ETL script with git**
- 이 모델에서 사용된 Feature 는 어떤 것이었지 ? **- mlflow logging**
- 어떤 Parameter 를 이용해서 학습을 진행했었지 ? **- mlflow logging**
- 실험 결과가 어디에 저장되어 있지 ? **- mlflow (tracking server / s3)**
- 학습된 모델의 버전은 어떻게 관리하지 ? **- mlflow model run id**
- 학습에 사용된 코드는 어떤 버전이지 ? **- mlflow with git**

모델을 배포하는 것에 난이도가 있습니다.

- 사용하는 프레임워크가 연구자마다 상이한데, 배포는 어떤 방식으로 진행하지?
- 배포된 모델의 버전관리는 어떻게하지?

2. MLflow 를 이용한 실습

1. Tracking server 를 설정하고 S3 와 연동하기
2. 임의의 Framework 에 대해 Customized 된 모델 mlflow 에 기록하기
3. mlflow에 기록된 모델을 Docker Image 화 하고, 실행시켜보기

2.1 Tracking server 를 설정하고 S3 와 연동하기

```
mlflow server \
    --backend-store-uri sqlite:///mlflow.db \
    --default-artifact-root s3://pycon2021/mlflow/ \
    --host 0.0.0.0 \
```

```
(pycon2021) sean@ip-192-168-0-5 scripts % bash 01.start_tracking_server.sh
[2021-08-04 08:13:43 +0900] [86510] [INFO] Starting gunicorn 20.1.0
[2021-08-04 08:13:43 +0900] [86510] [INFO] Listening at: http://0.0.0.0:5000 (86510)
[2021-08-04 08:13:43 +0900] [86510] [INFO] Using worker: sync
[2021-08-04 08:13:43 +0900] [86513] [INFO] Booting worker with pid: 86513
[2021-08-04 08:13:43 +0900] [86514] [INFO] Booting worker with pid: 86514
[2021-08-04 08:13:43 +0900] [86515] [INFO] Booting worker with pid: 86515
[2021-08-04 08:13:43 +0900] [86516] [INFO] Booting worker with pid: 86516
```

2.2 MLflow 에 Model 기록하기

- MLflow 는 **프레임워크에 관계없이** 모델을 패키징할 수 있는 방법을 제공합니다.
- artifacts 를 활용하여 모델의 추론에 필요한 임의의 파일을 Load 할 수 있습니다.

```python
import mlflow.pyfunc


# Define the model class
class AddN(mlflow.pyfunc.PythonModel):

    def __init__(self, n):
        self.n = n

    def predict(self, context, model_input):

        # some process using necessary_file
        with open(context.artifacts["necessary_file"], 'r') as f:
            print(f.read())

        return model_input.apply(lambda column: column + self.n)


if __name__ == "__main__":

    mlflow.set_tracking_uri("http://localhost:5000")
    experiment = mlflow.get_experiment_by_name("Pycon2021")

    with mlflow.start_run(experiment_id=experiment.experiment_id):

        artifacts = {
            "necessary_file" : "./necessary_file",
        }

        # Construct and save the model
        model_path = "add_n_model"
        add5_model = AddN(n=5)

        mlflow.pyfunc.log_model(
            artifact_path="models",
            python_model = add5_model,
            artifacts=artifacts)
```

2.3 MLflow에 기록된 모델로 Docker Image 만들기

```
# Build an image that can serve mlflow models.
ARG BASE_IMAGE=ubuntu:18.04

FROM ${BASE_IMAGE}

ARG MLFLOW_VER="1.19.0"

ENV MLFLOW_DISABLE_ENV_CREATION="true"
ENV DISABLE_NGINX="true"

RUN apt-get -y update \
       && apt-get install -y --no-install-recommends \
            wget \
            curl \
            ca-certificates \
            bzip2 \
            build-essential \
            cmake \
            git-core \
       && rm -rf /var/lib/apt/lists/*

# Download and setup miniconda
RUN curl -L https://repo.anaconda.com/miniconda/Miniconda3-latest-Linux-x86_64.sh >> miniconda.sh
RUN bash ./miniconda.sh -b -p /miniconda; rm ./miniconda.sh;
ENV PATH="/miniconda/bin:$PATH"

# Set up the program in the image
WORKDIR /opt/mlflow
RUN pip install "mlflow==${MLFLOW_VER}"
ADD model /opt/ml/model
RUN python -c "from mlflow.models.container import _install_pyfunc_deps; _install_pyfunc_deps('/opt/ml/model', install_mlflow=False)"

CMD /bin/bash -c "source /miniconda/bin/activate custom_env && gunicorn --bind=0.0.0.0:8080 mlflow.models.container.scoring_server.wsgi:app"

EXPOSE 8080
```

```
custom_img                    1.88GB
```

MATHPRESSO

2.3 mlflow에 기록된 모델에 요청 보내고 확인하기

```
sean@Seanui-MacBookPro ~ % docker run -p 8080:8080 ffbb27d2c2ef
[2021-08-03 23:28:30 +0000] [8] [INFO] Starting gunicorn 20.1.0
[2021-08-03 23:28:30 +0000] [8] [INFO] Listening at: http://0.0.0.0:8080 (8)
[2021-08-03 23:28:30 +0000] [8] [INFO] Using worker: sync
[2021-08-03 23:28:30 +0000] [21] [INFO] Booting worker with pid: 21
```